

第三讲 解线性方程组的迭代法

- 引言
- 基本迭代法
 - Jacobi迭代法
 - 高斯—赛德尔迭代法
 - 逐次超松弛法
- 迭代法的收敛性

一、引言

对线性方程组

$$Ax=b, \quad (1.1)$$

其中A为非奇异矩阵

- 当A为低阶稠密矩阵时, 选主元消去法是有效的.
- 对于大型稀疏矩阵方程组(A的阶数n很大, 但零元素较多), 利用迭代法求解是合适的.
- 迭代法缺点: 要求A具有某种特殊性质, 以保证迭代过程的收敛性
 - 发散的迭代过程是没有实用价值的。

本章将介绍: 迭代法基本理论、雅可比迭代法、高斯-赛德尔迭代法、超松弛迭代法、怎样构造迭代法、收敛性分析、收敛的判别条件。

方程组迭代法的构造原则

先将方程组 $Ax=b$ 改写为等价的形式： $x=Bx+f$

然后得到迭代格式： $x^{(k+1)}=Bx^{(k)}+f$

B 称为**迭代矩阵**

- 方程组的不同等价形式可得到不同的迭代格式
- 相应的迭代矩阵也不同。

例1 求解方程组

$$\begin{cases} 8x_1 - 3x_2 + 2x_3 = 20, \\ 4x_1 + 11x_2 - x_3 = 33, \\ 6x_1 + 3x_2 + 12x_3 = 36. \end{cases} \quad (1.2)$$

记为 $Ax=b$, 其中

$$A = \begin{pmatrix} 8 & -3 & 2 \\ 4 & 11 & -1 \\ 6 & 3 & 12 \end{pmatrix}, \quad x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}, \quad b = \begin{pmatrix} 20 \\ 33 \\ 36 \end{pmatrix}.$$

方程组的精确解是 $x^*=(3,2,1)^T$. 现将其改写为：

$$\begin{cases} x_1 = \frac{1}{8}(3x_2 - 2x_3 + 20), \\ x_2 = \frac{1}{11}(-4x_1 + x_3 + 33), \\ x_3 = \frac{1}{12}(-6x_1 - 3x_2 + 36). \end{cases} \quad (1.3)$$

或写为 $x = B_0 x + f$, 其中

$$B_0 = \begin{pmatrix} \mathbf{0} & \frac{3}{8} & -\frac{2}{8} \\ -\frac{4}{11} & \mathbf{0} & \frac{1}{11} \\ -\frac{6}{12} & -\frac{3}{12} & \mathbf{0} \end{pmatrix}, \quad f = \begin{pmatrix} \frac{20}{8} \\ \frac{33}{11} \\ \frac{36}{12} \end{pmatrix}.$$

任取 x 的初始值，例如取 $x^{(0)}=(0, 0, 0)^T$.

1. 将这些值代入(1.3)式右边(若(1.3)式为等式即求得方程组的解，但一般不满足)，得到新的值

$$x^{(1)}=(x_1^{(1)}, x_2^{(1)}, x_3^{(1)})^T = (3.5, 3, 3)^T$$

2. 再将 $x^{(1)}$ 分量代入(1.3)式右边得到 $x^{(2)}$

3. 反复利用这个计算程序，得到一向量序列和一般的计算公式(迭代公式)

$$x^{(0)} = \begin{pmatrix} x_1^{(0)} \\ x_2^{(0)} \\ x_3^{(0)} \end{pmatrix}, \quad x^{(1)} = \begin{pmatrix} x_1^{(1)} \\ x_2^{(1)} \\ x_3^{(1)} \end{pmatrix}, \quad \dots, \quad x^{(k)} = \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ x_3^{(k)} \end{pmatrix}, \quad \dots$$

$$\begin{cases} x_1^{(k+1)} = (3x_2^{(k)} - 2x_3^{(k)} + 20) / 8, \\ x_2^{(k+1)} = (-4x_1^{(k)} + x_3^{(k)} + 33) / 11, \\ x_3^{(k+1)} = (-6x_1^{(k)} - 3x_2^{(k)} + 36) / 12. \end{cases} \quad (1.4)$$

简写为： $x^{(k+1)} = B_0 x^{(k)} + f$,

其中 k 表示迭代次数($k=0,1,2,\dots$).

迭代到第10次有

$$x^{(10)} = (3.000032, 1.999838, 0.999813)^T;$$

$$\|\varepsilon^{(10)}\|_{\infty} = 0.000187 \quad (\varepsilon^{(10)} = x^{(10)} - x^*).$$


从此例看出：由迭代法产生的向量序列 $x^{(k)}$ 逐步逼近方程组的精确解 $x^*=(3,2,1)^T$. 即有

$$\lim_{k \rightarrow \infty} x^{(k)} = x^*$$

?? 对于任何一个方程组 $x=Bx+f$ (由 $Ax=b$ 变形得到的等价方程组), 由迭代法产生的向量序列 $x^{(k)}$ 是否一定逐步逼近方程组的解 x^* 呢? 回答是不一定.

——考虑用迭代法解下述方程组

$$\begin{cases} x_1 = 2x_2 + 5, \\ x_2 = 3x_1 + 5. \end{cases}$$



$x^{(k)}$ 并不是所有的都收敛到解 x^* !

对于给定方程组 $x=Bx+f$ ，设有唯一解 x^* ，则

$$x^*=Bx^*+f. \quad (1.5)$$

又设 $x^{(0)}$ 为任取的初始向量，按下述公式构造向量序列

$$x^{(k+1)}=Bx^{(k)}+f, \quad k=0,1,2,\dots. \quad (1.6)$$

其中 k 表示迭代次数.

定义1：

(1)对于给定的方程组 $x=Bx+f$ ，用公式(1.6)逐步代入求近似解的方法称为迭代法(或称为一阶定常迭代法，这里 B 与 k 无关). B 称为迭代矩阵.

(2) 如果 $\lim x^{(k)} (k \rightarrow \infty)$ 存在(记为 x^*)，称此迭代法收敛，显然 x^* 就是方程组的解，否则称此迭代法发散.

由上述讨论，需要研究 $\{x^{(k)}\}$ 的收敛性：

引进误差向量

$$\varepsilon^{(k+1)} = x^{(k+1)} - x^*,$$

由(1.6)减去(1.5)式，得 $\varepsilon^{(k+1)} = B\varepsilon^{(k)} (k=0,1,2,\dots)$

递推得：

$$\varepsilon^{(k)} = B\varepsilon^{(k-1)} = \dots = B^k \varepsilon^{(0)}.$$

要考察 $\{x^{(k)}\}$ 的收敛性，

- 研究 B 在什么条件下有 $\lim_{k \rightarrow \infty} \varepsilon^{(k)} = 0$ ，
- 亦即要研究 B 满足什么条件时有 $B^k \rightarrow 0$ (零向量) $(k \rightarrow \infty)$ 。

二、 基本迭代法

设线性方程组

$$Ax=b, \quad (2.1)$$

其中, $A=(a_{ij}) \in R^{n \times n}$ 为非奇异矩阵, 下面研究任何建立 $Ax=b$ 的各种迭代法.

将 A 分裂为

$$A=M-N. \quad (2.2)$$

其中, M 为可选择非奇异矩阵, 且使 $Mx=d$ 容易求解, 一般选择 A 的某种近似, 称 M 为分裂矩阵.

于是，求解 $Ax=b$ 转化为求解 $Mx=Nx+b$ ，即：

$$\text{求解 } Ax = b \Leftrightarrow \text{求解 } x = M^{-1}Nx + M^{-1}b.$$

可构造一阶定常迭代法

$$\begin{cases} x^{(0)} \text{ (初始向量),} \\ x^{(k+1)} = Bx^{(k)} + f \quad (k = 0, 1, \dots), \end{cases} \quad (2.3)$$

其中 $B=M^{-1}N=M^{-1}(M-A)=I-M^{-1}A$ ， $f=M^{-1}b$.

- 称 $B=I-M^{-1}A$ 为迭代法的迭代矩阵
- 选取不同的 M 矩阵，就得到解 $Ax=b$ 的各种迭代法.

设 $a_{ii} \neq 0$ ($i=1,2,\dots,n$) , 并将 A 写成三部分

$$\begin{aligned}
 A = & \begin{pmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & a_{nn} \end{pmatrix} - \begin{pmatrix} \mathbf{0} & & & & \\ -a_{21} & \mathbf{0} & & & \\ \vdots & \vdots & \ddots & & \\ -a_{n-1,1} & -a_{n-1,2} & \cdots & \mathbf{0} & \\ -a_{n1} & -a_{n2} & \cdots & -a_{n,n-1} & \mathbf{0} \end{pmatrix} \\
 & - \begin{pmatrix} \mathbf{0} & -a_{12} & \cdots & -a_{1,n-1} & -a_{1n} \\ & \mathbf{0} & \cdots & -a_{2,n-1} & -a_{2n} \\ & & \ddots & \vdots & \vdots \\ & & & \mathbf{0} & -a_{n-1,n} \\ & & & & \mathbf{0} \end{pmatrix} \\
 = & D - L - U.
 \end{aligned}$$

即 $A=D-L-U$

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

$$-L = \begin{bmatrix} 0 & & & \\ a_{21} & 0 & & \\ \vdots & \vdots & & \\ a_{n1} & a_{n2} & \cdots & 0 \end{bmatrix}$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix}$$

$$-U = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ & 0 & \cdots & a_{2n} \\ & & \ddots & \vdots \\ & & & 0 \end{bmatrix}$$

2.1 雅可比迭代法

设 $a_{ii} \neq 0$ ($i=1,2,\dots,n$),

- 选取 M 为 A 的对角元素部分,即选取 $M=D$ (对角阵),
- $A=D-N$
- 由(2.3)式得到解方程组 $Ax=b$ 的雅可比(Jacobi)迭代法. 又称简单迭代法.

$$\begin{cases} x^{(0)} & \text{(初始向量),} \\ x^{(k+1)} = Bx^{(k)} + f & (k = 0,1,\dots), \end{cases} \quad (2.5)$$

其中 $B=I-D^{-1}A=D^{-1}(L+U)=J$, $f=D^{-1}b$.

■ 称 J 为解 $Ax=b$ 的雅可比迭代法的迭代矩阵.

于是雅可比迭代法可写为矩阵形式

$$\mathbf{x}^{(k+1)} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} + \mathbf{D}^{-1}\mathbf{b}$$

其Jacobi迭代矩阵为

$$\mathbf{B}_J = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}) = \begin{pmatrix} \mathbf{0} & -\frac{a_{12}}{a_{11}} & \dots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & \mathbf{0} & \dots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \dots & \mathbf{0} \end{pmatrix}$$

下面给出雅可比迭代法(2.5)的分量计算公式, 记

$$\mathbf{x}^{(k)} = (x_1^{(k)}, \cdots, x_i^{(k)}, \cdots, x_n^{(k)})^T,$$

由雅可比迭代法(2.5)有

$$D\mathbf{x}^{(k+1)} = (L+U)\mathbf{x}^{(k)} + \mathbf{b},$$

每一个分量写出来为

$$a_{ii}x_i^{(k+1)} = -\sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} + b_i \quad (i=1,2,\cdots,n).$$

即当 $a_{ii} \neq 0$ 时, 有

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(-\sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} + b_i \right) \quad (i=1,2,\cdots,n).$$

即由方程组 $Ax=b$ 得到的

等价方程组

$$\begin{cases} x_1 = \frac{1}{a_{11}} [-a_{12}x_2 - \cdots - a_{1n}x_n + b_1] \\ x_2 = \frac{1}{a_{22}} [-a_{21}x_1 - \cdots - a_{2n}x_n + b_2] \\ \vdots \\ x_n = \frac{1}{a_{nn}} [-a_{n1}x_1 - a_{n2}x_2 - \cdots + b_n] \end{cases}$$

其中 $a_{ii}^{(i)} \neq 0$ ($i=1,2,\cdots,n$)

建立的雅可比迭代格式为

$$\left\{ \begin{array}{l} x_1^{(k+1)} = \frac{1}{a_{11}} (-a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)} + b_1) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (-a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)} + b_2) \\ \vdots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (-a_{n1}x_1^{(k)} - \cdots - a_{nn-1}x_{n-1}^{(k)} + b_n) \end{array} \right.$$

于是，解 $Ax=b$ 的雅可比迭代法的计算公式为

$$\begin{cases} x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T, \\ x_i^{(k+1)} = (b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)}) / a_{ii}, \\ (i = 1, 2, \dots, n) \quad (k = 0, 1, \dots \text{表示迭代次数}). \end{cases} \quad (2.6)$$

由(2.6)式可知:

- 雅可比迭代法计算公式简单
- 每迭代一次只需计算一次矩阵和向量的乘法
- 计算过程中原始矩阵 A 始终不变.

例:

$$\begin{cases} 10x_1 - 2x_2 - x_3 = 3 \\ -2x_1 + 10x_2 - x_3 = 15 \\ -x_1 - 2x_2 + 5x_3 = 10 \end{cases} \quad \text{准确解 } \mathbf{x} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

从第 k 个方程中解出 x_k ,
得到等价的方程组:

$$\begin{cases} x_1 = 0.2x_2 + 0.1x_3 + 0.3 \\ x_2 = 0.2x_1 + 0.1x_3 + 1.5 \\ x_3 = 0.2x_1 + 0.4x_2 + 2 \end{cases}$$

构造迭代格式:

$$\begin{cases} x_1^{(k+1)} = 0.2x_2^{(k)} + 0.1x_3^{(k)} + 0.3 \\ x_2^{(k+1)} = 0.2x_1^{(k)} + 0.1x_3^{(k)} + 1.5 \\ x_3^{(k+1)} = 0.2x_1^{(k)} + 0.4x_2^{(k)} + 2 \end{cases} \quad (*1)$$

在(*1)中, 令 $k=0$, 取 $x_1^{(0)}=0, x_2^{(0)}=0, x_3^{(0)}=0$ 代入,

得到: $x_1^{(1)}=0.3, x_2^{(1)}=1.5, x_3^{(1)}=2$

再令 $k=1$, 代入, 得: $x_1^{(2)}=0.8, x_2^{(2)}=1.76, x_3^{(2)}=2.66$

再令 $k=2$, 代入, 得: $x_1^{(3)}=0.918, x_2^{(3)}=1.921, x_3^{(3)}=2.864$

$$\begin{cases} x_1^{(k+1)} = 0.2x_2^{(k)} + 0.1x_3^{(k)} + 0.3 \\ x_2^{(k+1)} = 0.2x_1^{(k)} + 0.1x_3^{(k)} + 1.5 \\ x_3^{(k+1)} = 0.2x_1^{(k)} + 0.4x_2^{(k)} + 2 \end{cases} \quad (*1)$$

在(*1)中, 令 $k=0$, 取 $x_1^{(0)}=0, x_2^{(0)}=0, x_3^{(0)}=0$ 代入,

得到: $x_1^{(1)}=0.3, x_2^{(1)}=1.5, x_3^{(1)}=2$

再令 $k=1$, 代入, 得: $x_1^{(2)}=0.8, x_2^{(2)}=1.76, x_3^{(2)}=2.66$

再令 $k=2$, 代入, 得: $x_1^{(3)}=0.918, x_2^{(3)}=1.921, x_3^{(3)}=2.864$

k	$x_1^{(k+1)}$	$x_2^{(k+1)}$	$x_3^{(k+1)}$
3	0.9716	1.97	2.954
4	0.9894	1.98972	2.98232
5	0.996176	1.996112	2.993768
...
8	0.999814032	1.999814544	2.999693216
9	0.999932230	1.999932128	2.999888624
10	0.999975288	1.999975308	2.999959297

迭代格式 (*1) :

$$\begin{cases} x_1^{(k+1)} = 0.2x_2^{(k)} + 0.1x_3^{(k)} + 0.3 \\ x_2^{(k+1)} = 0.2x_1^{(k)} + 0.1x_3^{(k)} + 1.5 \\ x_3^{(k+1)} = 0.2x_1^{(k)} + 0.4x_2^{(k)} + 2 \end{cases} \quad \text{Jacobi迭代格式}$$

写为矩阵向量形式: $\vec{x}^{(k+1)} = B \times \vec{x}^{(k)} + \vec{f}$

其中:

$$\vec{x}^{(k)} = \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \\ x_3^{(k)} \end{pmatrix} \quad B = \begin{pmatrix} 0 & 0.2 & 0.1 \\ 0.2 & 0 & 0.1 \\ 0.2 & 0.4 & 0 \end{pmatrix} \quad \vec{f} = \begin{pmatrix} 0.3 \\ 1.5 \\ 2 \end{pmatrix}$$

B称为迭代矩阵

2.2 高斯-赛德尔迭代法

在 Jacobi 迭代中，计算 $x_i^{(k+1)}$ ($2 \leq i \leq n$) 时，使用 $x_j^{(k+1)}$ 代替 $x_j^{(k)}$ ($1 \leq j \leq i-1$)，即有

建立迭代格式

$$\begin{cases} x_1^{(k+1)} = \frac{1}{a_{11}} (-a_{12} x_2^{(k)} - a_{13} x_3^{(k)} - \cdots - a_{1n} x_n^{(k)} + b_1) \\ x_2^{(k+1)} = \frac{1}{a_{22}} (-a_{21} x_1^{(k+1)} - a_{23} x_3^{(k)} - \cdots - a_{2n} x_n^{(k)} + b_2) \\ \vdots \\ x_n^{(k+1)} = \frac{1}{a_{nn}} (-a_{n1} x_1^{(k+1)} - \cdots - a_{nn-1} x_{n-1}^{(k+1)} + b_n) \end{cases}$$

Gauss-Seidel迭代:

$$\begin{array}{l}
 \vdots \\
 x_1^{(k+1)} = \frac{1}{a_{11}} (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)}) \\
 \vdots \\
 x_2^{(k+1)} = \frac{1}{a_{22}} (b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)}) \\
 \vdots \\
 x_3^{(k+1)} = \frac{1}{a_{33}} (b_3 - a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} - a_{34}x_4^{(k)} - \dots - a_{3n}x_n^{(k)}) \\
 \vdots \\
 \dots\dots\dots \\
 \vdots \\
 x_n^{(k+1)} = \frac{1}{a_{nn}} (b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \dots - a_{nn-1}x_{n-1}^{(k+1)}) \\
 \vdots \\
 \uparrow
 \end{array}$$

old

new

或写为:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(-\sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} + b_i \right) \quad (i = 1, 2, \dots, n).$$

称为高斯—塞德尔(Gauss — Seidel)迭代法.

将Gauss-Seidel迭代表示为矩阵向量形式.

$$A=D-L-U, \text{ 方程组 } Ax=b \text{ 可以写为: } (D-L-U)x=b$$

$$\longrightarrow Dx=(Lx+Ux)+b$$

$$\text{写为迭代格式: } Dx^{(k+1)}=(Lx^{(k+1)}+Ux^{(k)})+b$$

$$(D-L)x^{(k+1)}=Ux^{(k)}+b$$

$$x^{(k+1)}=(D-L)^{-1}Ux^{(k)}+(D-L)^{-1}b$$

$$\text{或 } x^{(k+1)}=Gx^{(k)}+f$$

$$\text{其中: } G=(D-L)^{-1}U, \quad f=(D-L)^{-1}b$$

G称为Gauss-Seidel迭代的迭代矩阵

$$B_G = (D-L)^{-1}U$$

这就是说，选取分裂矩阵 M 为 A 的下三角部分，即选取 $M = D - L$ (下三角阵)， $A = M - N$ ，由(2.3)式得到解 $Ax = b$ 的高斯—塞德尔(Gauss — Seidel)迭代法.

$$\begin{cases} x^{(0)} & \text{(初始向量),} \\ x^{(k+1)} = Bx^{(k)} + f & (k = 0, 1, \dots), \end{cases} \quad (2.7)$$

其中 $B = I - (D - L)^{-1}A = (D - L)^{-1}U = G$ ， $f = (D - L)^{-1}b$. 称矩阵 $G = (D - L)^{-1}U$ 为解 $Ax = b$ 的高斯—塞德尔迭代法的迭代矩阵.

由高斯—塞德尔迭代法(2.7)有

$$(D-L)x^{(k+1)} = Ux^{(k)} + b,$$

或

$$Dx^{(k+1)} = Lx^{(k+1)} + Ux^{(k)} + b,$$

每一个分量写出来为

$$a_{ii}x_i^{(k+1)} = b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \quad (i=1,2,\cdots,n).$$

即当 $a_{ii} \neq 0$ 时, 有(与前面一样的式子)

$$x_i^{(k+1)} = \frac{1}{a_{ii}} (b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)}) \quad (i=1,2,\cdots,n).$$

于是，解 $Ax=b$ 的高斯—塞德尔迭代法的计算公式为

$$\begin{cases} x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T \text{ (初始向量),} \\ x_i^{(k+1)} = (b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)}) / a_{ii}, \\ (i = 1, 2, \dots, n) \text{ (} k = 0, 1, \dots \text{ 表示迭代次数).} \end{cases} \quad (2.8)$$

$$\text{或} \begin{cases} x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T, \\ x_i^{(k+1)} = x_i^{(k)} + \Delta x_i, \\ \Delta x_i = (b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)}) / a_{ii}, \\ (i = 1, 2, \dots, n) \text{ (} k = 0, 1, \dots \text{).} \end{cases} \quad (2.9)$$

雅可比迭代法不使用变量的最新信息计算 $x_i^{(k+1)}$ ，而由高斯—塞德尔迭代公式(2.8)可知，计算 $x^{(k+1)}$ 的第 i 个分量 $x_i^{(k+1)}$ 时，利用了已经计算出的最新分量 $x_j^{(k+1)}$ ($j=1,2,\dots,i-1$). 可看作雅可比迭代法的一种改进. 由(2.8)可知，高斯—塞德尔迭代公式每迭代一次只需计算一次矩阵与向量的乘法.

例 用雅可比迭代法解方程组

$$\begin{cases} 10x_1 - x_2 - 2x_3 = 7.2 \\ -x_1 + 10x_2 - 2x_3 = 8.3 \\ -x_1 - x_2 + 5x_3 = 4.2 \end{cases} \quad \begin{array}{l} \text{精} \\ \text{确} \\ \text{解} \end{array} \quad x^* = \begin{pmatrix} 1.1 \\ 1.2 \\ 1.3 \end{pmatrix}.$$

解：Jacobi 迭代格式为

$$\begin{cases} x_1^{(k+1)} = \frac{1}{10} (x_2^{(k)} + 2x_3^{(k)} + 7.2) \\ x_2^{(k+1)} = \frac{1}{10} (x_1^{(k)} + 2x_3^{(k)} + 8.3) \\ x_3^{(k+1)} = \frac{1}{5} (x_1^{(k)} + x_2^{(k)} + 4.2) \end{cases}$$

$$\begin{cases} x_1^{(k+1)} = \frac{1}{10} (x_2^{(k)} + 2x_3^{(k)} + 7.2) \\ x_2^{(k+1)} = \frac{1}{10} (x_1^{(k)} + 2x_3^{(k)} + 8.3) \\ x_3^{(k+1)} = \frac{1}{5} (x_1^{(k)} + x_2^{(k)} + 4.2) \end{cases}$$

取 $x^{(0)} = (0, 0, 0)^T$ 计算结果如下：

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$
1	0.72	0.83	0.84
2	0.971	1.07	1.15
...
11	1.099993	1.199993	1.299991
12	1.099998	1.199998	1.299997

用Gauss—Seidel 迭代法解上题.

$$\begin{cases} 10x_1 - x_2 - 2x_3 = 7.2 \\ -x_1 + 10x_2 - 2x_3 = 8.3 \\ -x_1 - x_2 + 5x_3 = 4.2 \end{cases}$$

解： Gauss-Seidel 迭代格式为

$$\begin{cases} x_1^{(k+1)} = \frac{1}{10} (x_2^{(k)} + 2x_3^{(k)} + 7.2) \\ x_2^{(k+1)} = \frac{1}{10} (x_1^{(k+1)} + 2x_3^{(k)} + 8.3) \\ x_3^{(k+1)} = \frac{1}{5} (x_1^{(k+1)} + x_2^{(k+1)} + 4.2) \end{cases}$$

$$\begin{cases} x_1^{(k+1)} = \frac{1}{10} (x_2^{(k)} + 2x_3^{(k)} + 7.2) \\ x_2^{(k+1)} = \frac{1}{10} (x_1^{(k+1)} + 2x_3^{(k)} + 8.3) \\ x_3^{(k+1)} = \frac{1}{5} (x_1^{(k+1)} + x_2^{(k+1)} + 4.2) \end{cases}$$

取 $x^{(0)} = (0, 0, 0)^T$ 计算结果如下：

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$
1	0.72	0.902	1.1644
...
8	1.0999998	1.1999999	1.3

由此例可知，用高斯—塞德尔迭代法，雅可比迭代法解线性方程组(且取 $x^{(0)}=0$)均收敛，而高斯—塞德尔迭代法比雅可比迭代法收敛较快(即取相同的 $x^{(0)}$ ，达到同样精度所需迭代次数较少)，但这结论只当A满足一定条件时才是对的。

2.3 逐次超松弛法

解大型稀疏线性方程组的逐次超松弛法(SOR方法)

为加快迭代法的收敛速度，考察Gauss-Seidel迭代：

$$\begin{aligned}x_i^{(k+1)} &= \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right) \\&= x_i^{(k)} + \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n\end{aligned}$$

第k+1次的迭代值可以看成是第k次迭代值加修正项。

为加速收敛，对修正项乘以调节因子 ω ：

$$x_i^{(k+1)} = x_i^{(k)} + \omega \cdot \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n$$

ω 称为松弛因子，可通过改变 ω 的值加速收敛。

该方法称为逐次超松弛迭代法，简称SOR迭代法。

$\omega < 1$ ，为低松弛迭代法； $\omega > 1$ ，为超松弛迭代法。

$\omega = 1$ 为 Gauss-Seidel 迭代。

算法：

$$\begin{cases} y_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), i = 1, 2, \dots, n \\ x_i^{(k+1)} = x_i^{(k)} + \omega (y_i^{(k+1)} - x_i^{(k)}) \end{cases}$$

$$\because x_i^{(k+1)} = x_i^{(k)} + \omega (y_i^{(k+1)} - x_i^{(k)}) = (1 - \omega) x_i^{(k)} + \omega y_i^{(k+1)}$$

$\therefore x_i^{(k+1)}$ 是 $x_i^{(k)}$ 与 $y_i^{(k+1)}$ 的加权平均。

下面用矩阵方法推导：

选取分裂矩阵 M 为带参数的下三角矩阵

$$M = \frac{1}{\omega} (D - \omega L).$$

其中 $\omega > 0$ 为可选择的松弛因子.

于是，由(2.3)可构造一个迭代法，其迭代矩阵为

$$\begin{aligned} L_{\omega} &= I - \omega(D - \omega L)^{-1} A \\ &= (D - \omega L)^{-1} [(1 - \omega)D + \omega U]. \end{aligned}$$

从而得到解 $Ax=b$ 的逐次超松弛迭代法 (Successive Over Relaxation Method，简称SOR方法).

解 $Ax=b$ 的SOR方法为.

$$\begin{cases} x^{(0)} & \text{(初始向量),} \\ x^{(k+1)} = L_{\omega} x^{(k)} + f & (k = 0, 1, \dots), \end{cases} \quad (2.10)$$

其中 $L_{\omega} = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$, $f = \omega(D - \omega L)^{-1}b$.

下面给出解 $Ax=b$ 的SOR方法的分量计算公式. 记

$$x^{(k)} = (x_1^{(k)}, \dots, x_i^{(k)}, \dots, x_n^{(k)})^T,$$

由(2.10)式可得

$$(D - \omega L)x^{(k+1)} = [(1 - \omega)D + \omega U]x^{(k)} + \omega b,$$

$$Dx^{(k+1)} = Dx^{(k)} + \omega(b + Lx^{(k+1)} + Ux^{(k)} - Dx^{(k)}).$$

由此，得到解 $Ax=b$ 的SOR方法的计算公式

$$\begin{cases} x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T, \\ x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)}) / a_{ii} \\ (i = 1, 2, \dots, n; k = 0, 1, 2, \dots), \omega \text{ 为松弛因子} \end{cases} \quad (2.11)$$

或

$$\begin{cases} x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T, \\ x_i^{(k+1)} = x_i^{(k)} + \Delta x_i, \\ \Delta x_i = \omega(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i}^n a_{ij}x_j^{(k)}) / a_{ii} \\ (i = 1, 2, \dots, n; k = 0, 1, 2, \dots), \omega \text{ 为松弛因子} \end{cases} \quad (2.12)$$

(1) 显然，当 $\omega=1$ 时即为Gauss—Seidel 迭代法.

(2) SOR方法每迭代一次主要运算量是计算一次矩阵与向量的乘法.

(3) 当 $\omega>1$ 时，称为超松弛法；当 $\omega<1$ 时，称为低松弛法.

(4) 在计算机实现时可用

$$\max_{1 \leq i \leq n} |\Delta x_i| = \max_{1 \leq i \leq n} |x_i^{(k+1)} - x_i^{(k)}| < \varepsilon$$

控制迭代终止，或用

$$\|r^{(k)}\|_{\infty} = \|b - Ax^{(k)}\|_{\infty} < \varepsilon$$

控制迭代终止.

SOR迭代法是Gauss—Seidel 迭代法的一种修正，可由下述思想得到.

设已知 $x^{(k)}$ 及已计算 $x^{(k+1)}$ 的分量 $x_j^{(k+1)}$ ($j=1,2,\dots,i-1$).

(1) 首先用Gauss—Seidel 迭代法定义辅助量 $\tilde{x}_i^{(k+1)}$,

$$\tilde{x}_i^{(k+1)} = (b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)}) / a_{ii}. \quad (2.13)$$

(2) 再由 $x_i^{(k)}$ 与 $\tilde{x}_i^{(k+1)}$ 加权平均定义 $x_i^{(k+1)}$, 即

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega \tilde{x}_i^{(k+1)} = x_i^{(k)} + \omega (\tilde{x}_i^{(k+1)} - x_i^{(k)}). \quad (2.14)$$

将(2.13)代入(2.14)得到解 $Ax=b$ 的SOR迭代(2.11)式.

对于方程组 $\mathbf{Ax}=\mathbf{b}$ $A = \begin{pmatrix} 4 & -1 & 0 & -1 & 0 & 0 \\ -1 & 4 & -1 & \ddots & \ddots & 0 \\ 0 & -1 & 4 & \ddots & \ddots & -1 \\ -1 & \ddots & \ddots & \ddots & \ddots & 0 \\ 0 & \ddots & \ddots & -1 & 4 & -1 \\ 0 & 0 & -1 & 0 & -1 & 4 \end{pmatrix}$

同样的精度，用Jacobi迭代法, 需要**1154**次. ($\rho(B_J)=0.9877$)

用G-S迭代法, 需要**578**次。

用SOR方法

ω	1	1.7	1.72	1.737	1.74
次数	578	78	66	54	57

三、 迭代法的收敛性

3.1 一阶定常迭代法的基本定理

一阶定常迭代法的基本定理

设线性方程组 $Ax=b$, (3.1)

其中, $A=(a_{ij})\in R^{n\times n}$ 为非奇异矩阵, 记 x^* 为(3.1)精确解, 且设有等价的方程组

$$Ax = b \Leftrightarrow x = Bx + f.$$

于是

$$x^* = Bx^* + f. \quad (3.2)$$

设有解 $Ax=b$ 的一阶定常迭代法

$$x^{(k+1)} = Bx^{(k)} + f. \quad (3.3)$$

设方程组 $Ax=b$ 的准确解为 x^* ，迭代格式为：

$$x^{(k+1)} = Bx^{(k)} + f \quad B \text{ 为迭代矩阵}$$

若迭代产生的序列 $\{x^{(k)}\}$ 收敛，设 $\lim_{k \rightarrow \infty} x^{(k)} = \tilde{x}$

对 $x^{(k+1)} = Bx^{(k)} + f$ 两边求极限，得 $\tilde{x} = B\tilde{x} + f$

而 $x = Bx + f$ 是 $Ax=b$ 的等价方程组，所以有 $A\tilde{x} = b$ ，
即 \tilde{x} 是方程组 $Ax=b$ 的准确解。

因此，只要迭代格式收敛，一定收敛到方程组的准确解。

有意义的问题是：迭代矩阵 B 满足什么条件时，由迭代法产生的向量序列 $\{x^{(k)}\}$ 收敛到 x^* 。

引进误差向量

$$\varepsilon^{(k)} = x^{(k)} - x^* \quad (k = 0, 1, 2, \dots).$$

由(3.3)式减(3.2)得到误差向量的递推公式

$$\varepsilon^{(k+1)} = B\varepsilon^{(k)}, \quad \varepsilon^{(k)} = B^k \varepsilon^{(0)} \quad (k = 0, 1, 2, \dots).$$

研究迭代法(3.3)收敛性问题就是要研究迭代矩阵 B 满足什么条件时，有。

$$B^k \rightarrow 0 \text{ (零矩阵)} (k \rightarrow \infty).$$

定义2 设有矩阵序列 $A_k=(a_{ij}^{(k)})\in R^{n\times n}$ 及 $A=(a_{ij})\in R^{n\times n}$, 如果 n^2 个数列极限存在且有

$$\lim_{k\rightarrow\infty} a_{ij}^{(k)} = a_{ij} \quad (i, j = 1, 2, \dots, n).$$

则 $\{A_k\}$ 称收敛于 A , 记为 $\lim (k\rightarrow\infty)$.

例4 设有矩阵序列 $\{A_k\}$, 其中 $A_k=B^k$, 而

$$B = \begin{pmatrix} \lambda & 1 \\ 0 & \lambda \end{pmatrix}, B^2 = \begin{pmatrix} \lambda^2 & 2\lambda \\ 0 & \lambda^2 \end{pmatrix}, \dots, B^k = \begin{pmatrix} \lambda^k & k\lambda^{k-1} \\ 0 & \lambda^k \end{pmatrix}, \dots$$

且设 $|\lambda|<1$, 考查矩阵序列极限.

解 显然, 当 $|\lambda|<1$ 时, 则有 $\lim_{k\rightarrow\infty} A_k = \lim_{k\rightarrow\infty} B^k = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$

矩阵序列极限概念可以用矩阵算子范数来描述.

定理1 $\lim_{k \rightarrow \infty} A_k = A \Leftrightarrow \lim_{k \rightarrow \infty} \|A_k - A\| = 0$, 其中 $\|\cdot\|$ 为矩阵的任意一种算子范数.

证明 显然有

$$\lim_{k \rightarrow \infty} A_k = A \Leftrightarrow \lim_{k \rightarrow \infty} \|A_k - A\|_{\infty} = 0.$$

再由矩阵范数的等价性, 则定理对其它算子范数亦对.

定理2 $\lim_{k \rightarrow \infty} A_k = A \Leftrightarrow$ 对 $\forall x \in R^n$ 都有 $\lim_{k \rightarrow \infty} A_k x = Ax$.

定理3 设 $B=(b_{ij})\in R^{n\times n}$, 则 $\lim B^k=0$ ($k\rightarrow\infty$)(零矩阵)的充分必要条件是矩阵 B 的谱半径 $\rho(B)<1$. (自习)

证明 由矩阵 B 的若当标准形,存在非奇异矩阵 P 使

$$P^{-1}BP = \begin{pmatrix} J_1 & & & \\ & J_2 & & \\ & & \ddots & \\ & & & J_r \end{pmatrix} \equiv J,$$

其中若当(Jordan)块

$$J_i = \begin{pmatrix} \lambda_i & 1 & & \\ & \lambda_i & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_i \end{pmatrix}_{n_i \times n_i},$$

且 $\sum_{i=1}^r n_i = n$, 显然有

$$B = PJP^{-1}, \quad B^k = PJ^kP^{-1},$$

其中

$$J^k = \begin{pmatrix} J_1^k & & & \\ & J_2^k & & \\ & & \ddots & \\ & & & J_r^k \end{pmatrix}.$$

于是 $\lim_{k \rightarrow \infty} B^k = 0 \Leftrightarrow \lim_{k \rightarrow \infty} J^k = 0 \Leftrightarrow \lim_{k \rightarrow \infty} J_i^k = 0, (i = 1, 2, \cdots, r).$

下面考查 J_i^k 的情况. 引进记号

$$E_{t,k} = \begin{pmatrix} \mathbf{0} & I \\ \mathbf{0} & \mathbf{0} \end{pmatrix}^{t-k} \in R^{t \times t} \quad (t = n_i).$$

显然有, $E_{t,0}=I$, $E_{t,k}=0$ (当 $k \geq t$) , $(E_{t,1})^k = E_{t,k}$. 由于 $J_i = \lambda I + E_{t,1}$, 因此

$$\begin{aligned} J_i^k &= (\lambda_i I + E_{t,1})^k = \sum_{j=0}^k C_k^j \lambda_i^{k-j} (E_{t,1})^j \\ &= \sum_{j=0}^{t-1} C_k^j \lambda_i^{k-j} (E_{t,1})^j \end{aligned}$$

$$= \begin{pmatrix} \lambda_i^k & C_k^1 \lambda_i^{k-1} & C_k^2 \lambda_i^{k-2} & C_k^{t-1} \lambda_i^{k-(t-1)} \\ & \lambda_i^k & C_k^1 \lambda_i^{k-1} & C_k^{t-2} \lambda_i^{k-(t-2)} \\ & & & C_k^1 \lambda_i^{k-1} \\ & & & \lambda_i^k \end{pmatrix}_{t \times t}$$

$$(i = 1, 2, \dots, r).$$

其中 $C_k^j = \frac{k!}{j!(k-j)!} = \frac{k(k-1)\cdots(k-j+1)}{j!}.$

利用极限 $\lim_{k \rightarrow \infty} k^r c^k = 0 (0 < c < 1, r \geq 0)$, 得到

$$\lim_{k \rightarrow \infty} C_k^j \lambda^{k-j} = 0 \Leftrightarrow |\lambda| < 1.$$

所以 $\lim_{k \rightarrow \infty} J_i^k = 0 \Leftrightarrow |\lambda_i| < 1 (i = 1, 2, \dots, r)$, 即 $\rho(B) < 1$.

定理4(迭代法基本定理) 设有方程组

$$\mathbf{x} = \mathbf{B}\mathbf{x} + \mathbf{f}. \quad (3.4)$$

及一阶定常迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}. \quad (3.5)$$

对任意选择初始向量 $\mathbf{x}^{(0)}$ ，迭代法(3.5)收敛的充要条件是矩阵 \mathbf{B} 的谱半径 $\rho(\mathbf{B}) < 1$. (自习)

证明 充分性. 设 $\rho(\mathbf{B}) < 1$ ，易知 $\mathbf{A}\mathbf{x} = \mathbf{f}$ (其中 $\mathbf{A} = \mathbf{I} - \mathbf{B}$)有唯一解，记为 \mathbf{x}^* ，则

$$\mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{f}.$$

误差向量

$$\boldsymbol{\varepsilon}^{(k)} = \mathbf{x}^{(k)} - \mathbf{x}^* = \mathbf{B}^k \boldsymbol{\varepsilon}^{(0)}, \quad \boldsymbol{\varepsilon}^{(0)} = \mathbf{x}^{(0)} - \mathbf{x}^*.$$

由设 $\rho(B) < 1$ ，应用定理3，有 $\lim_{k \rightarrow \infty} B^k = 0$ 。于是对任意 $x^{(0)}$ 有 $\lim_{k \rightarrow \infty} \varepsilon^k = 0$ ，即 $\lim_{k \rightarrow \infty} x^{(k)} = x^*$ 。

必要性. 设对任何 $x^{(0)}$ 有

$$\lim_{k \rightarrow \infty} x^{(k)} = x^*,$$

其中 $x^{(k+1)} = Bx^{(k)} + f$ 。显然，极限 x^* 是方程组(3.4)的解，且对任意 $x^{(0)}$ 有

$$\varepsilon^{(k)} = x^{(k)} - x^* = B^k \varepsilon^{(0)} \rightarrow 0 (k \rightarrow \infty).$$

由定理2知

$$\lim_{k \rightarrow \infty} B^k = 0$$

再由定理3，即得 $\rho(B) < 1$ 。

定理4是一阶定常迭代法的基本理论。

定理3和定理4的结论和起来即为

(1) 迭代法 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 收敛 $\Leftrightarrow \lim \mathbf{B}^k = \mathbf{O}$;

(2) 迭代法 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 收敛 $\Leftrightarrow \rho(\mathbf{B}) < 1$.

推论 设 $\mathbf{A}\mathbf{x} = \mathbf{b}$, 其中 $\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$ 为非奇异矩阵且 \mathbf{D} 非奇异矩阵, 则有

(1) Jacobi迭代法收敛 $\Leftrightarrow \rho(\mathbf{J}) < 1$, 其中 $\mathbf{J} = \mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})$.

(2) G-S迭代法收敛 $\Leftrightarrow \rho(\mathbf{G}) < 1$, 其中 $\mathbf{G} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}$.

(3) SOR迭代法收敛 $\Leftrightarrow \rho(\mathbf{L}_\omega) < 1$, 其中

$$\mathbf{L}_\omega = (\mathbf{D} - \omega\mathbf{L})^{-1}[(1 - \omega)\mathbf{D} + \omega\mathbf{U}].$$

例5 考察用Jacobi方法解方程组(1.2)的收敛性.

解 因为方程组(1.2)的矩阵**A**及迭代矩阵**J**为

$$A = \begin{pmatrix} 8 & -3 & 2 \\ 4 & 11 & -1 \\ 6 & 3 & 12 \end{pmatrix}, J = D^{-1}(L+U) = \begin{pmatrix} 0 & 3/8 & -2/8 \\ -4/11 & 0 & 1/11 \\ -6/12 & -3/12 & 0 \end{pmatrix}.$$

得迭代矩阵**J**的特征方程为

$$\det(\lambda I - J) = \lambda^3 + \frac{3}{88}\lambda + \frac{3}{176}$$

$$= \lambda^3 + 0.034090909\lambda + 0.039772727 = 0,$$

解得

$$\lambda_1 = -0.3082, \lambda_2 = 0.1841 + 0.3445i, \lambda_3 = 0.1841 - 0.3445i,$$

$$|\lambda_1| = 0.3082 < 1, |\lambda_2| = |\lambda_3| = 0.3592 < 1.$$

即 $\rho(J) < 1$. 所以用Jacobi方法解方程组(1.2)是收敛的.

例6 考察用迭代法解方程组的收敛性. 其中

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}, \quad \mathbf{B} = \begin{pmatrix} 0 & 2 \\ 3 & 0 \end{pmatrix}, \quad \mathbf{f} = \begin{pmatrix} 5 \\ 5 \end{pmatrix}.$$

解 方程组的迭代矩阵 \mathbf{B} 的特征方程为

$$\det(\lambda \mathbf{I} - \mathbf{B}) = \begin{vmatrix} \lambda & -2 \\ -3 & \lambda \end{vmatrix} = \lambda^2 - 6,$$

矩阵 \mathbf{B} 的特征值为 $\lambda_{1,2} = \pm\sqrt{6}$, 即 $\rho(\mathbf{B}) > 1$.

这说明用迭代法解此方程组**不收敛**.

迭代法的基本定理在理论上是重要的, 根据谱半径的性质 $\rho(\mathbf{B}) \leq \|\mathbf{B}\|$, 下面利用矩阵 \mathbf{B} 的范数建立判别迭代法收敛的充分条件.

设 \mathbf{A} 为 n 阶方阵,则对任意算子范数 $|| \cdot ||$
有

$$\rho(\mathbf{A}) \leq \|\mathbf{A}\|$$

推论 迭代格式 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 所得序列 $\{\mathbf{x}^{(k)}\}$ 收敛的
充分条件是 \mathbf{B} 的任何一种范数 $||\mathbf{B}|| < 1$ 。

证明：若 \mathbf{B} 的某种矩阵范数 $||\mathbf{B}|| < 1$,

$\rho(\mathbf{B}) \leq \|\mathbf{B}\| < 1$, 从而迭代格式收敛。

迭代格式的收敛速度问题

设迭代矩阵 \mathbf{B} 有 n 个线性无关特征向量 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 相应特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$ 。线性无关向量 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 可以作为 \mathbf{R}^n 空间的一组基，任意向量可用 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 展开。

$$\therefore \boldsymbol{\varepsilon}^{(0)} = \sum_{i=1}^n c_i \mathbf{u}_i$$

$$\therefore \boldsymbol{\varepsilon}^{(k)} = \mathbf{B}^k \boldsymbol{\varepsilon}^{(0)} = \sum_{i=1}^n c_i \mathbf{B}^k \mathbf{u}_i = \sum_{i=1}^n c_i \lambda_i^k \mathbf{u}_i$$

$$\|\boldsymbol{\varepsilon}^{(k)}\| = \left\| \sum_{i=1}^n c_i \lambda_i^k \mathbf{u}_i \right\| \leq \sum_{i=1}^n |c_i| \cdot |\lambda_i|^k \cdot \|\mathbf{u}_i\| \leq \rho^k(\mathbf{B}) \sum_{i=1}^n |c_i| \cdot \|\mathbf{u}_i\|$$

\therefore 若 $\rho(\mathbf{B}) < 1$ ，则 $\|\boldsymbol{\varepsilon}^{(k)}\| \rightarrow 0$ ，迭代收敛

$\rho(\mathbf{B}) < 1$ 越小， $\|\boldsymbol{\varepsilon}^{(k)}\|$ 趋于0的速度越快，因此，可用 $\rho(\mathbf{B})$ 衡量收敛速度。

迭代格式的收敛性判别

定理4 迭代格式 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 所得序列 $\{\mathbf{x}^{(k)}\}$ 收敛的充要条件是 \mathbf{B} 的谱半径小于1。

推论 迭代格式 $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$ 所得序列 $\{\mathbf{x}^{(k)}\}$ 收敛的充分条件是 \mathbf{B} 的任何一种范数 $\|\mathbf{B}\| < 1$ 。

因为 $\rho(\mathbf{B}) = \max_i |\lambda_B^{(i)}|$ ，计算困难，一般先用推论，由 $\|\mathbf{B}\| < 1$ 判别收敛性。

注：只能用推论判别迭代格式的收敛，
不能用推论判别迭代格式的发散。

例：两种迭代的迭代矩阵

$$\begin{cases} 10x_1 - 2x_2 - x_3 = 3 \\ -2x_1 + 10x_2 - x_3 = 15 \\ -x_1 - 2x_2 + 5x_3 = 10 \end{cases} \quad A = \begin{pmatrix} 10 & -2 & -1 \\ -2 & 10 & -1 \\ -1 & -2 & 5 \end{pmatrix} \quad \text{令 } A = D - L - U$$

$$\text{则: } D = \begin{pmatrix} 10 & 0 & 0 \\ 0 & 10 & 0 \\ 0 & 0 & 5 \end{pmatrix}, \quad L = \begin{pmatrix} 0 & 0 & 0 \\ 2 & 0 & 0 \\ 1 & 2 & 0 \end{pmatrix}, \quad U = \begin{pmatrix} 0 & 2 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix} \quad \text{注意L, U 元素的符号}$$

Jacobi迭代:

$$B = D^{-1}(L + U) = \begin{pmatrix} 10 & 0 & 0 \\ 0 & 10 & 0 \\ 0 & 0 & 5 \end{pmatrix}^{-1} \begin{pmatrix} 0 & 2 & 1 \\ 2 & 0 & 1 \\ 1 & 2 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0.2 & 0.1 \\ 0.2 & 0 & 0.1 \\ 0.2 & 0.4 & 0 \end{pmatrix}$$

Gauss-Seidel迭代:

$$G = (D - L)^{-1}U = \begin{pmatrix} 10 & 0 & 0 \\ -2 & 10 & 0 \\ -1 & -2 & 5 \end{pmatrix}^{-1} \begin{pmatrix} 0 & 2 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0.2 & 0.1 \\ 0 & 0.04 & 0.12 \\ 0 & 0.056 & 0.068 \end{pmatrix}$$

Jacobi迭代矩阵为B

$$B = \begin{pmatrix} 0 & 0.2 & 0.1 \\ 0.2 & 0 & 0.1 \\ 0.2 & 0.4 & 0 \end{pmatrix} \quad \because \|B\|_1 = 0.6 < 1, \quad \therefore \text{Jacobi迭代收敛。}$$

Gauss-Seidel迭代矩阵为G

$$G = \begin{pmatrix} 0 & 0.2 & 0.1 \\ 0 & 0.04 & 0.12 \\ 0 & 0.056 & 0.068 \end{pmatrix} \quad \because \|G\|_1 = 0.296 < 1, \quad \therefore \text{Gauss-Seidel迭代收敛。}$$

实际上，可以求出： $\rho(B) = 0.3646$ ， $\rho(G) = 0.137$

$\rho(G)$ 较小，收敛速度快。这与算例中，Gauss-Seidel迭代收敛较快相一致。

例3. 方程组 $Ax=b$, $A=\begin{pmatrix} 0.1 & 0 \\ -0.3 & 0.2 \end{pmatrix}$, $b=\begin{pmatrix} 1 \\ 2 \end{pmatrix}$, 解 $x=\begin{pmatrix} 10 \\ 25 \end{pmatrix}$

将方程组写为等价的形式, $x=(I-A)x+b$,

构造迭代格式: $x^{(k+1)} = (I-A)x^{(k)} + b$

迭代矩阵 $B = I - A = \begin{pmatrix} 0.9 & 0 \\ 0.3 & 0.8 \end{pmatrix}$,

求出: $\|B\|_{\infty} = 1.1 > 1$, $\|B\|_1 = 1.2 > 1$, $\|B\|_F = 1.241 > 1$,

但是不能得出迭代发散的结论。

实际上, B 的特征值为0.9, 0.8, $\rho(B)=0.9 < 1$,

迭代是收敛的。但 $\rho(B)=0.9$ 较大, 收敛较慢。

$$x_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad x_{10} = \begin{bmatrix} 6.51322 \\ 15.07652 \end{bmatrix} \quad x_{25} = \begin{bmatrix} 9.2821 \\ 22.8652 \end{bmatrix} \quad x_{50} = \begin{bmatrix} 9.94846 \\ 24.84546 \end{bmatrix} \quad x_{100} = \begin{bmatrix} 9.99973 \\ 24.9992 \end{bmatrix}$$

定理5(迭代法收敛的充分条件) 设有方程组

$$\mathbf{x} = \mathbf{B}\mathbf{x} + \mathbf{f}, \quad \mathbf{B} = (b_{ij}) \in \mathbb{R}^{n \times n},$$

及一阶定常迭代法

$$\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}.$$

如果有 \mathbf{B} 的某种算子范数 $\|\mathbf{B}\| = q < 1$, 则

(1) 迭代法收敛, 即对任取 $\mathbf{x}^{(0)}$ 有
$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*, \quad \text{且} \quad \mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{f}.$$

$$(2) \quad \|\mathbf{x}^* - \mathbf{x}^{(k)}\| \leq q^k \|\mathbf{x}^* - \mathbf{x}^{(0)}\|.$$

$$(3) \quad \|\mathbf{x}^* - \mathbf{x}^{(k)}\| \leq \frac{q}{1-q} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|.$$

$$(4) \quad \|\mathbf{x}^* - \mathbf{x}^{(k)}\| \leq \frac{q^k}{1-q} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|.$$

证明 (1)由基本定理4结论(1)是显然的.

(2) 显然有关系式 $x^*-x^{(k+1)}=B(x^*-x^{(k)})$ 及
 $x^{(k+1)}-x^{(k)}=B(x^{(k)}-x^{(k-1)})$.

于是有 (a) $||x^{(k+1)}-x^{(k)}|| \leq q ||x^{(k)}-x^{(k-1)}||$;

(b) $||x^*-x^{(k+1)}|| \leq q ||x^*-x^{(k)}||$.

反复利用(b)即得(2).

(3) 考查 $||x^{(k+1)}-x^{(k)}|| = ||x^*-x^{(k)}-(x^*-x^{(k+1)})||$
 $\geq ||x^*-x^{(k)}|| - ||x^*-x^{(k+1)}||$
 $\geq (1-q)||x^*-x^{(k)}||,$

即得

$$\|x^* - x^{(k)}\| \leq \frac{1}{1-q} \|x^{(k+1)} - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\|.$$

(4) 利用(3)的结果反复利用(a), 则得到(4). 即

$$\|x^* - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\| \leq \dots \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|.$$

由迭代矩阵 $\|B\| < 1$ 不但可判别收敛性, 还可估计迭代的精度。

注1: 定理5表示, 当 $\mathbf{x}^{(k)}$ 与 $\mathbf{x}^{(k-1)}$ 充分接近时,
一般, $\mathbf{x}^{(k)}$ 与 \mathbf{x}^* 也充分接近。

因此, 可用 $\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\| < \varepsilon$ 作为迭代的停止准则。

注2: 当 $\|B\| < 1$ 且充分接近1时, $\frac{\|B\|}{1 - \|B\|}$ 很大,

尽管 $\|x^{(k)} - x^{(k-1)}\|$ 很小, 但 $\|x^{(k)} - x^*\|$ 仍然较大,
迭代收敛可能很慢。

例如：方程组
$$\begin{cases} 10^6 x_1 - 999999 x_2 = 1 \\ -999999 x_1 + 10^6 x_2 = 1 \end{cases} \quad \text{解 } x^* = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Jacobi迭代：
$$\vec{x}^{(k+1)} = \begin{pmatrix} 0 & 0.999999 \\ 0.999999 & 0 \end{pmatrix} \vec{x}^{(k)} + \begin{pmatrix} 10^{-6} \\ 10^{-6} \end{pmatrix}$$

$$x^{(0)} = \begin{pmatrix} 0.1 \\ 0.1 \end{pmatrix}, x^{(1)} = \begin{pmatrix} 0.100001 \\ 0.100001 \end{pmatrix}, x^{(2)} = \begin{pmatrix} 0.100002 \\ 0.100002 \end{pmatrix}, x^{(3)} = \begin{pmatrix} 0.100003 \\ 0.100003 \end{pmatrix}, \dots$$

此时， $x^{(k)}$ 与 $x^{(k+1)}$ 很接近， $\|x^{(3)} - x^{(2)}\|_{\infty} < 10^{-6}$ ，

但 $x^{(k)}$ 与 x^* 相差很远。原因 $\|B\|_1 = 0.999999$ ，很接近1

用 $\|x^{(k-1)} - x^{(k)}\| < \varepsilon$ 作为迭代的停止准则要注意这一点。

3.2 特殊方程组迭代法的收敛性

关于解某些特殊方程组迭代法的收敛性

在科学及工程计算中，要求解方程组 $Ax=b$ ，其矩阵 A 常常具有某些特性。例如， A 具有对角占优性质或 A 为不可约阵，或 A 是对称正定阵，下面讨论用基本迭代法解这些方程组的收敛性。

定义3(对角占优阵) 设 $A=(a_{ij})_{n \times n}$.

(1) 如果 A 的元素满足

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \quad (i = 1, 2, \dots, n).$$

称 A 为严格(按行)对角占优阵.

(2) 如果 A 的元素满足

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \quad (i = 1, 2, \dots, n).$$

且上式至少有一个不等式成立, 称 A 为弱(按行)对角占优阵.

定义4(可约与不可约矩阵) 设 $A=(a_{ij})_{n \times n}$ ($n \geq 2$) , 如果存在置换阵 P 使

$$P^T A P = \begin{pmatrix} A_{11} & A_{12} \\ \mathbf{0} & A_{22} \end{pmatrix}, \quad (3.6)$$

其中 A_{11} 为 r 阶方阵, A_{22} 为 $n-r$ 阶方阵($1 \leq r \leq n$), 则称 A 为**可约矩阵**. 否则, 如果不存在这样置换阵 P 使(3.6)式成立, 则称 A 为**不可约矩阵**.

A 为可约矩阵意即 A 可经过若干行列重排化为(3.6)或 $Ax=b$ 可化为两个低阶方程组求解(如果 A 经过两行交换的同时进行相应两列的交换, 称对 A 进行一次行列重排).

事实上，由 $Ax=b$ 可化为

$$P^T A P (P^T x) = P^T b.$$

且记 $y = P^T x = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$, $d = P^T b = \begin{pmatrix} d_1 \\ d_2 \end{pmatrix}$, 其中 y_i , d_i 为 r 维向量.

于是，求解 $Ax=b$ 化为求解

$$\begin{cases} A_{11}y_1 + A_{12}y_2 = d_1, \\ A_{22}y_2 = d_2. \end{cases}$$

由上式第2个方程组求出 y_2 ,再代入第1个方程组求出 y_1 .

显然，如果 A 所有元素都非零，则 A 为不可约阵.

A是可约矩阵的充要条件是存在一个下标的非空子集

$$J \subseteq \{1, 2, \dots, n\}$$

使得

$$a_{kj} = 0, k \in J, j \notin J.$$

等价的定义：

$A = \{a_{ij}\}_{n \times n}$ ，设 $N = \{1, 2, \dots, n\}$ ，若存在集合 N 的子集 I, J 满足 $I \cup J = N, I \cap J = \Phi$ ，使得对 $i \in I, j \in J$ 的一切 $a_{ij} = 0$ ，则称 A 为可约矩阵，否则称 A 为不可约。

例：

$$A = \begin{pmatrix} \times & \times & \times & \times \\ 0 & \times & \times & 0 \\ 0 & \times & \times & 0 \\ \times & \times & \times & \times \end{pmatrix} \quad P = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix} \quad P^T A P = \begin{pmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \end{pmatrix}$$

或： $N = \{1,2,3,4\}$, 取 $I = \{2,3\}$, $J = \{1,4\}$,

对任意 $i \in I$, $j \in J$, 有 $a_{ij} = 0$.

因此 **A** 是可约矩阵。

例 设有矩阵

$$A = \begin{pmatrix} b_1 & c_1 & & \\ a_2 & b_2 & c_2 & \\ & & & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix}, B = \begin{pmatrix} 4 & -1 & -1 & 0 \\ -1 & 4 & 0 & -1 \\ -1 & 0 & 4 & -1 \\ 0 & -1 & -1 & 4 \end{pmatrix}.$$

$(a_i, b_i, c_i \text{ 都不为零})$

则A, B都是不可约矩阵.

定理6(对角占优定理) 如果 $A=(a_{ij})_{n \times n}$ 为严格对角占优矩阵或 A 为不可约弱对角占优矩阵, 则 A 为非奇异矩阵.

证明 只就 A 为严格对角占优矩阵证明此定理. 采用反证法, 如果 $\det(A)=0$, 则 $Ax=b$ 有非零解, 记为 $x=(x_1, x_2, \dots, x_n)^T$, 则 $|x_k| = \max_{1 \leq i \leq n} |x_i| \neq 0$.

由齐次方程组第 k 个方程
$$\sum_{j=1}^n a_{kj} x_j = 0,$$

则有 $|a_{kk} x_k| = \left| \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj} x_j \right| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| |x_j| \leq |x_k| \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|$, 即 $|a_{kk}| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|$,

这与假设矛盾, 故 $\det(A) \neq 0$.

定理7 设方程组 $Ax=b$ ，如果

(1) A 为严格对角占优阵，则解 $Ax=b$ 的Jacobi迭代法, Gauss-Seidel 迭代法均收敛.

(2) A 为弱对角占优阵，且 A 为不可约矩阵，则解 $Ax=b$ 的Jacobi迭代法, Gauss-Seidel 迭代法均收敛.

证明 只证(1)，(2)作为思考题.

因为 A 是严格对角占优阵，所以 $a_{ii} \neq 0 (i=1, \dots, n)$.

Jacobi迭代阵

$$J = D^{-1}(L+U) = \begin{pmatrix} 0 & -\frac{a_{12}}{a_{11}} & \dots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & \dots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \dots & 0 \end{pmatrix}$$

则 $\|J\|_{\infty} < 1$ ，所以 Jacobi 迭代法收敛.

下面证明 Gauss—Seidel 迭代法收敛.

由 $G = (D - L)^{-1}U$, 得

$$\begin{aligned}\det(\lambda I - G) &= \det[\lambda I - (D - L)^{-1}U] \\ &= \det[(D - L)^{-1}] \det[\lambda (D - L) - U] = 0.\end{aligned}$$

由于 $\det[(D - L)^{-1}] \neq 0$.

所以 $\det[\lambda (D - L) - U] = 0$. (*)

下面证明 $|\lambda| < 1$. 若不然, 即 $|\lambda| \geq 1$, 则

$$|\lambda a_{ii}| > \sum_{j \neq i} |\lambda a_{ij}| \geq \sum_{j=1}^{i-1} |\lambda a_{ij}| + \sum_{j=i+1}^n |a_{ij}| \quad (i = 1, 2, \dots, n).$$

$$|\lambda a_{ii}| > \sum_{j \neq i} |\lambda a_{ij}| \geq \sum_{j=1}^{i-1} |\lambda a_{ij}| + \sum_{j=i+1}^n |a_{ij}| \quad (i=1,2,\dots,n).$$

即矩阵

$$\lambda (D-L)-U = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}.$$

是严格对角占优矩阵，故可逆，这与(*) 式矛盾，所以 $|\lambda| < 1$ ，从而 $\rho(G) < 1$ ，即 Gauss—Seidel 迭代法收敛。

定理 若A为正定矩阵，则方程组 $Ax=b$ 的 Gauss-Seidel 迭代法收敛. (自习)

证 因为 $A=D-L-L^T$, $G=(D-L)^{-1}L^T$, 设 λ 为 G 的特征值 , y 为对应的特征(复)向量 , 即

$$(D-L)^{-1}L^Ty=\lambda y \text{ , } L^Ty=\lambda(D-L)y \text{ ,}$$

则内积 $(L^Ty, y)=\lambda((D-L)y, y)$.

从而

$$\lambda = \frac{(L^T y, y)}{(Dy, y) - (Ly, y)}.$$

因为A正定，所以D正定，故 $(Dy, y)=\sigma>0$.

令 $-(Ly, y) = a + ib$, 则由复向量内积的性质有

$$(L^T y, y) = (y, Ly) = \overline{(Ly, y)} = -(a - ib).$$

$$\lambda = \frac{(L^T y, y)}{(Dy, y) - (Ly, y)} = \frac{-a + ib}{(\sigma + a) + ib}.$$

$$|\lambda|^2 = \frac{a^2 + b^2}{(\sigma + a)^2 + b^2} < 1$$

所以 $|\lambda| < 1$, 从而 $\rho(G) < 1$, 故 Gauss-Seidel 迭代法收敛.

下面研究对于解方程组 $Ax = b$ 的 SOR 方法中松弛因子 ω 在什么范围内取值, SOR 方法才可能收敛.

定理8(SOR方法收敛的必要条件) 设解方程组 $Ax=b$ 的SOR迭代法收敛, 则 $0<\omega<2$.

证 $A=D-L-U$, $L_\omega=(D-\omega L)^{-1}[(1-\omega)D + \omega U]$, 由于SOR迭代法收敛, 则 $\rho(L_\omega)<1$. 设迭代矩阵 L_ω 的特征值为 λ_i ($i=1, \dots, n$), 则有 $\det(L_\omega) < |\lambda_1 \lambda_2 \cdots \lambda_n| < [\rho(L_\omega)]^n < 1$.

于是

$$\begin{aligned}\det(L_\omega) &= \det[(D - \omega L)^{-1}] \cdot \det[(1 - \omega)D + \omega U] \\ &= \left(\prod_{i=1}^n a_{ii}\right)^{-1} \left[\prod_{i=1}^n (1 - \omega)a_{ii}\right] = (1 - \omega)^n < 1.\end{aligned}$$

所以 $|1 - \omega| < 1$, 即 $0 < \omega < 2$.

定理8说明解 $Ax=b$ 的SOR迭代法，只有在 $(0, 2)$ 范围内取松弛因子 ω ，才可能收敛.

定理9(SOR方法收敛的充分条件) 设有方程组 $Ax=b$,
如果：

(1) A 为对称正定矩阵， $A=D-L-L^T$;

(2) $0<\omega<2$.

则解方程组 $Ax=b$ 的SOR迭代法收敛. (自习)

证 在上述假定下，设迭代矩阵 L_ω 的任一特征值为 λ ，只要证明 $|\lambda|<1$ 即可.

事实上，设 y 为对应 λ 的 L_ω 的特征向量，即

$$L_\omega y = \lambda y, \quad y = (y_1, y_2, \dots, y_n)^T \neq 0,$$

$$(D - \omega L)^{-1} ((1 - \omega)D + \omega L^T) y = \lambda y,$$

亦即 $((1 - \omega)D + \omega L^T) y = \lambda (D - \omega L) y.$

有内积 $((1 - \omega)D + \omega L^T) y, y) = \lambda ((D - \omega L) y, y),$

则
$$\lambda = \frac{(Dy, y) - \omega(Dy, y) + \omega(L^T y, y)}{(Dy, y) - \omega(Ly, y)},$$

因为 A 正定，所以 D 正定，记 $(Dy, y) = \sigma > 0$.

令 $-(Ly, y) = a + ib$ ，则由复向量内积的性质有

$$(L^T y, y) = (y, Ly) = \overline{(Ly, y)} = -(a - ib).$$

$$\begin{aligned}\lambda &= \frac{(Dy, y) - \omega(Dy, y) + \omega(L^T y, y)}{(Dy, y) - \omega(Ly, y)}, \\ &= \frac{(\sigma - \omega\sigma - a\omega) + i\omega b}{(\sigma + a\omega) + i\omega b}. \\ |\lambda|^2 &= \frac{(\sigma - \omega\sigma - a\omega)^2 + \omega^2 b^2}{(\sigma + a\omega)^2 + \omega^2 b^2}.\end{aligned}$$

因为 $0 < (Ay, y) = ((D - L - L^T)y, y) = \sigma + 2a$,

当 $0 < \omega < 2$ 时, 有(分子减分母)

$$(\sigma - \omega\sigma - a\omega)^2 - (\sigma + a\omega)^2 = \omega\sigma(\sigma + 2a)(\omega - 2) < 0.$$

即 L_ω 的任一特征值满足 $|\lambda| < 1$, 故SOR迭代法收敛.

注1： 对不满足定理7的矩阵**A**，**J**迭代和**G-S**迭代的收敛可能不一致。

$$\text{如, } A_1 = \begin{pmatrix} 1 & -2 & 2 \\ -1 & 1 & -1 \\ -2 & -2 & 1 \end{pmatrix}, \text{ J迭代收敛, G-S迭代不收敛。}$$

$$A_2 = \begin{pmatrix} 1 & 1/2 & 1/2 \\ 1/2 & 1 & 1/2 \\ 1/2 & 1/2 & 1 \end{pmatrix}, \text{ G-S迭代收敛, J迭代不收敛。}$$

注2： 两者都收敛时，并不总是**G-S**迭代的收敛速度快于**J**迭代的收敛速度。

注3（定理）：若 A 是对称正定矩阵，则SOR方法收敛的充要条件是 $0 < \omega < 2$.

注4：当 A 为 n 阶对称正定矩阵时，可用共轭斜量法 (conjugate gradient method, CG) 来解 $Ax=b$ 。（自学）

程序简单、存储需要量小、特别适合求解大型稀疏问题

例

下面是一个14*14的矩阵

a1 =

3.0000	-1.0000	0	0	0	0	0	0	0	0	0	0	0	0.5000
-1.0000	3.0000	-1.0000	0	0	0	0	0	0	0	0	0	0.5000	0
0	-1.0000	3.0000	-1.0000	0	0	0	0	0	0	0	0.5000	0	0
0	0	-1.0000	3.0000	-1.0000	0	0	0	0	0	0.5000	0	0	0
0	0	0	-1.0000	3.0000	-1.0000	0	0	0	0.5000	0	0	0	0
0	0	0	0	-1.0000	3.0000	-1.0000	0	0.5000	0	0	0	0	0
0	0	0	0	0	-1.0000	3.0000	-1.0000	0	0	0	0	0	0
0	0	0	0	0	0	-1.0000	3.0000	-1.0000	0	0	0	0	0
0	0	0	0	0	0	0.5000	0	-1.0000	3.0000	-1.0000	0	0	0
0	0	0	0	0.5000	0	0	0	-1.0000	3.0000	-1.0000	0	0	0
0	0	0	0.5000	0	0	0	0	0	-1.0000	3.0000	-1.0000	0	0
0	0	0.5000	0	0	0	0	0	0	0	-1.0000	3.0000	-1.0000	0
0	0.5000	0	0	0	0	0	0	0	0	0	-1.0000	3.0000	-1.0000
0.5000	0	0	0	0	0	0	0	0	0	0	0	-1.0000	3.0000

LU分解得到的下三角矩阵L

L =

1.0000	0	0	0	0	0	0	0	0	0	0	0	0	0	0
-0.3333	1.0000	0	0	0	0	0	0	0	0	0	0	0	0	0
0	-0.3750	1.0000	0	0	0	0	0	0	0	0	0	0	0	0
0	0	-0.3810	1.0000	0	0	0	0	0	0	0	0	0	0	0
0	0	0	-0.3818	1.0000	0	0	0	0	0	0	0	0	0	0
0	0	0	0	-0.3819	1.0000	0	0	0	0	0	0	0	0	0
0	0	0	0	0	-0.3820	1.0000	0	0	0	0	0	0	0	0
0	0	0	0	0	0	-0.3820	1.0000	0	0	0	0	0	0	0
0	0	0	0	0	0.1910	0.0729	-0.3541	1.0000	0	0	0	0	0	0
0	0	0	0	0.1910	0.0729	0.0279	0.0106	-0.4027	1.0000	0	0	0	0	0
0	0	0	0.1909	0.0729	0.0279	0.0106	0.0041	-0.0048	-0.4237	1.0000	0	0	0	0
0	0	0.1905	0.0727	0.0278	0.0106	0.0041	0.0015	-0.0018	-0.0073	-0.4297	1.0000	0	0	0
0	0.1875	0.0714	0.0273	0.0104	0.0040	0.0015	0.0006	-0.0007	-0.0027	-0.0077	-0.4308	1.0000	0	0
0.1667	0.0625	0.0238	0.0091	0.0035	0.0013	0.0005	0.0002	-0.0002	-0.0009	-0.0026	-0.0068	-0.4281	1.0000	0

LU分解得到的上三角矩阵U

U =

3.0000	-1.0000	0	0	0	0	0	0	0	0	0	0	0	0.5000
0	2.6667	-1.0000	0	0	0	0	0	0	0	0	0	0.5000	0.1667
0	0	2.6250	-1.0000	0	0	0	0	0	0	0	0.5000	0.1875	0.0625
0	0	0	2.6190	-1.0000	0	0	0	0	0	0.5000	0.1905	0.0714	0.0238
0	0	0	0	2.6182	-1.0000	0	0	0	0.5000	0.1909	0.0727	0.0273	0.0091
0	0	0	0	0	2.6181	-1.0000	0	0.5000	0.1910	0.0729	0.0278	0.0104	0.0035
0	0	0	0	0	0	2.6180	-1.0000	0.1910	0.0729	0.0279	0.0106	0.0040	0.0013
0	0	0	0	0	0	0	2.6180	-0.9271	0.0279	0.0106	0.0041	0.0015	0.0005
0	0	0	0	0	0	0	0	2.5623	-1.0319	-0.0122	-0.0046	-0.0017	-0.0006
0	0	0	0	0	0	0	0	0	2.4727	-1.0476	-0.0181	-0.0068	-0.0023
0	0	0	0	0	0	0	0	0	0	2.4444	-1.0503	-0.0189	-0.0063
0	0	0	0	0	0	0	0	0	0	0	2.4371	-1.0499	-0.0166
0	0	0	0	0	0	0	0	0	0	0	0	2.4381	-1.0437
0	0	0	0	0	0	0	0	0	0	0	0	0	2.4576

将上述形式的矩阵扩展到高阶的矩阵，用 $Matlab$ 的 LU 分解软件进行 LU 分解，用 CPU 时间如下（秒）：

500阶	1000阶	1500阶	2000阶	2008阶	2500阶	3000阶
0.0470	0.3130	1.1250	5.9840	6.0940	14.8750	27.9220

取精确解 X 的分量都为1，取初始值为0，用共轭斜量法进行计算：

3000阶，精确度为 10^{-16} ，*cpu*时间0.0620秒

100万阶，精确度为 10^{-16} ，*cpu*时间15.8910秒

300万阶，精确度为 10^{-16} ，*cpu*时间28.4380秒

习题

P.216 第1题、第5题；

P.217 第9题；

P.218 第14题